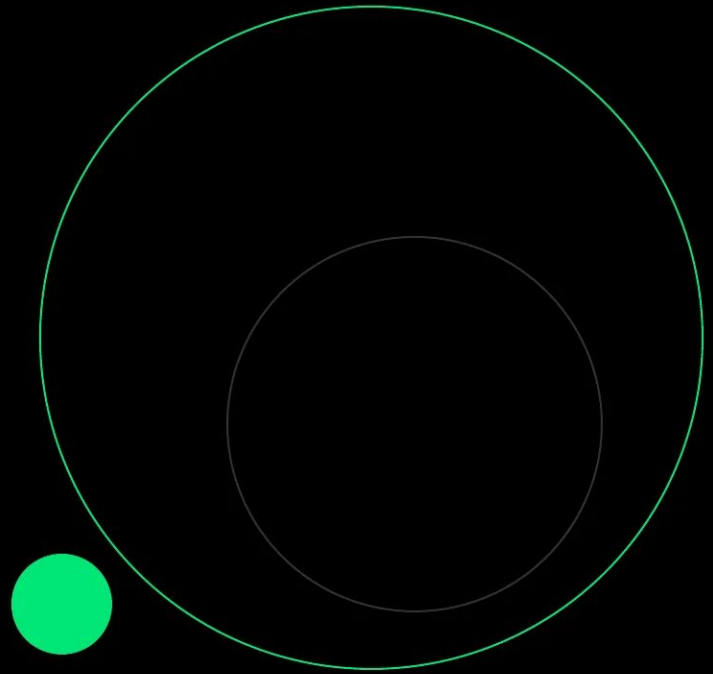
Прогнозирование индекса селективности (SI) против вируса оспы.

Решение команды Anti7

- Задача: оценка потенциала малых молекул исключительно по химической формуле (SMILES)
- Фокус: честное обобщение на новые классы соединений без использования внешних баз и статей



Что мы предсказываем и почему это сложно?

Регрессия на данных с экстремальным разбросом

- **Индекс селективности (SI)** — отношение цитотоксичности к противовирусной активности:

$$SI = CC50 / IC50$$

- **Вызов метрики (Raw MSE):** квадратичный штраф гиперчувствителен к крупным значениям — ошибка даже на одной супер-активной молекуле способна разрушить общий скор. Поэтому приходится применять точечную калибровку.

95%

веществ имеют SI < 50

10 000+

редкие супер-ингибиторы с SI > 10 000

Осознанный выбор: от «лик-решения» к чистому ML

Почему мы отказались от «идеального» скора?

01

Что мы проверили сначала

Поиск тестовых молекул по DOI и открытым публикациям дал скор ≈ 82.72.

02

Консультация с организаторами

Цель хакатона — инструмент для новых (de novo) молекул. Поиск по статьям эксплуатирует data leakage и бесполезен для реальной разработки лекарств.

03

Принципиальное решение

Сняли аналитический сабмит и сфокусировались на полноценной модели классического машинного обучения.

«Оцифровка» молекул

Перевод химического графа в признаки для деревьев

01

Morgan Fingerprints

ECFP4 и ECFP6 · 2048 бит

Кодируют локальные атомные окружения разного радиуса — от отдельных функциональных групп до крупных полициклов.

02

MACCS Keys

166 бит

Бинарный чек-лист стандартных структурных фрагментов и гетероатомов.

03

RDKit 2D

208 признаков

Молекулярный вес (MW), липофильность (MolLogP), полярная поверхность (TPSA), доноры и акцепторы водородной связи (HBD/HBA).

Защита от переобучения: Bemis-Murcko Split

Почему стандартный Random K-Fold ошибается?

Проблема Random K-Fold

Случайное разбиение отправляет близкие химические аналоги одной серии и в train, и в validation. Модель заучивает каркас и дает иллюзию точности.

Решение — Bemis-Murcko Scaffold Split

GroupKFold

Группировка молекул строго по базовым углеродным каркасам.

Результат: фолд-модели тестируются на химических семействах, которых они никогда не видели при обучении. Это гарантирует реальную генерализацию и устойчивость — подтверждено высоким баллом на private-части.

Архитектура ансамбля и динамика метрики

Пошаговое снижение MSE от бейзлайна к финальному решению

- **Трансформация таргета:** обучение на шкале log(SI + 1) для сдерживания дисперсии и стабильности градиентов бустинга.
- **Ансамбль разнородных моделей:** взвешенный стек CatBoost + LightGBM + XGBoost (усреднение 15 фолд-моделей).

Эксперимент	Что добавили	MSE
exp_001	Базовый бустинг без структуры	≈ 1 983 000
exp_002–008	+ Дескрипторы RDKit и ECFP	≈ 987 000
exp_010–016	+ Лог-таргет и скаффолд-сплит	≈ 589 000
exp_018	**Ансамбль + калибровка масштаба пиков**	**12 611 (Public) 12 982 (Private)**

Скорость, автономность и надежность

Решение, готовое к мгновенному аудиту

100%

автономность: никаких запросов в сеть, API или внешних баз

2.9%

разница между Public и Private скором — отсутствие переобучения

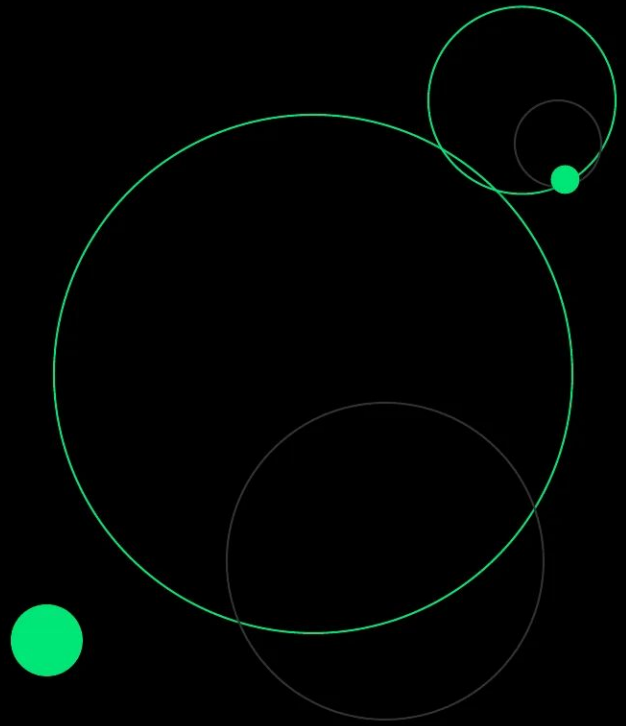
1 команда

python run_solution.py с путями --test, --train, --output

Итоги работы

Практический инструмент для скрининга новых молекул

- Построен надежный и быстрый ML-пайплайн для оценки противовирусного потенциала новых химических соединений.
- Реализованы признанные стандарты Data Science: ансамбль бустингов, продвинутый feature engineering.



Команда Anti7

Спасибо за внимание!

Готовы ответить на ваши вопросы.